

Urban Traffic

Diego Jesús Puentes Fernández

Amalia González

1. Descripción del proyecto

Objetivo central: generar, almacenar, procesar y visualizar datos sintéticos de flujo vehicular urbano para analizar patrones, entrenar modelos predictivos y detectar anomalías. El sistema combina procesamiento por lotes (*batch*) y en flujo continuo (*streaming*).

2. ¿Qué se pretende lograr?

Analizar y modelar el tráfico urbano mediante datos sintéticos reproducibles para evaluar algoritmos de predicción, detección de congestión y visualización bajo distintos volúmenes de datos.

3. Dataset original

Referencia: **UK Road Traffic Dataset** (Kaggle, autor: Arash Nic). Formato CSV. Columnas principales:

- Identificadores: `count_point_id`, `year`, `count_date`, `hour`
- Localización: `region_name`, `local_authority_name`, `road_name`, `road_type`
- Coordenadas: `easting`, `northing`, `latitude`, `longitude`
- Longitudes: `link_length_km`, `link_length_miles`
- Conteos vehiculares: `pedal_cycles`, `cars_and_taxis`, `buses_and_coaches`, `lgvs`, `hgvs_*`, `all_hgvs`, `all_motor_vehicles`

El conjunto describe tráfico por hora, tipo de vía y región, con etiquetas adecuadas para estimar perfiles de comportamiento vehicular y espacial.

4. Arquitectura y flujo de trabajo general

El flujo completo del sistema es el siguiente:

1. **Carga estática** → Lectura del dataset original y limpieza de registros.
2. **Perfiles estadísticos** → Cálculo de distribuciones y parámetros numéricos resumidos y almacenamiento en JSON.
3. **Generador sintético** → Uso de los perfiles para producir registros nuevos coherentes con las distribuciones originales.
4. **Almacenamiento en HDFS** → Escritura de datos sintéticos en formato JSONL dentro del sistema Hadoop.
5. **Visualización** → Lectura de los datos desde HDFS y representación mediante Streamlit.

Representación general:

Dataset estático → Perfiles estadísticos → Generador sintético → HDFS → Dashboard Streamlit

5. Paso 1: carga y perfilado del dataset estático

A partir del dataset se construyen los siguientes elementos matemáticos:

- **Distribuciones categóricas:**

$$p_i = \frac{n_i}{\sum_j n_j}$$

donde n_i es el número de observaciones de la categoría i .

- **Perfiles numéricos:** Para cada variable continua x :

$$\mu_{\log} = \frac{1}{N} \sum_{i=1}^N \log(1 + x_i)$$

$$\sigma_{\log} = \sqrt{\frac{1}{N} \sum_{i=1}^N (\log(1 + x_i) - \mu_{\log})^2}$$

$$p_{05} = \text{percentil}_{0,05}(x), \quad p_{95} = \text{percentil}_{0,95}(x)$$

- **Proporciones vehiculares:**

$$s_k = \frac{v_k}{\sum_j v_j}$$

donde v_k es el conteo de una clase de vehículo y la suma en el denominador representa el total de vehículos.

Si no existe dataset estático, el sistema usa perfiles por defecto con parámetros fijos de media, desviación y proporciones predefinidas.

6. Paso 2: fundamentos matemáticos del generador sintético

El generador usa los perfiles obtenidos para crear registros nuevos de tráfico según leyes probabilísticas.

6.1. Muestreo numérico

Cada variable numérica se obtiene aplicando una distribución log-normal truncada:

$$x = \min \left(\max \left(e^Z - 1, p_{05} \right), p_{95} \right)$$

donde $Z \sim \mathcal{N}(\mu_{\log}, \sigma_{\log}^2)$. Esto garantiza valores positivos y coherentes con los límites empíricos.

6.2. Muestreo de proporciones

Las proporciones de tipos de vehículos o clases de vías se generan como:

$$s \sim \mathcal{N}(\bar{s}, \sigma_s^2)$$

con recorte en el intervalo $[0, 0.95]$ y normalización para que $\sum_k s_k = 1$.

6.3. Cálculo del número total de vehículos

El total estimado por segmento de vía combina densidad, longitud y volumen regional:

$$T = \text{round} \left(\max \left(\frac{d \cdot L + V}{2}, 1 \right) \right)$$

donde d es la densidad media, L la longitud del tramo y V el volumen esperado de la región.

6.4. Desglose de vehículos pesados

El total pesado se calcula como:

$$H = T \cdot s_h$$

donde s_h es la proporción de tráfico pesado. El desglose en subcategorías se reparte proporcionalmente manteniendo $\sum_i h_i = H$.

6.5. Muestreo espacial

Las coordenadas se generan a partir de distribuciones normales centradas en los promedios geográficos de cada autoridad local:

$$E \sim \mathcal{N}(\bar{E}, \sigma_E^2), \quad N \sim \mathcal{N}(\bar{N}, \sigma_N^2)$$

donde E y N son easting y northing respectivamente.

7. Paso 3: funcionamiento del generador

El proceso sigue los pasos:

1. Cargar perfiles numéricos y categóricos.
2. Seleccionar una combinación de región, autoridad y tipo de vía.
3. Generar valores numéricos y proporciones mediante las distribuciones definidas.
4. Calcular los conteos vehiculares totales y parciales.
5. Registrar el resultado en formato JSON.

La frecuencia de generación está determinada por una tasa fija de emisión en registros por minuto.

8. Paso 4: almacenamiento en Hadoop

Los datos generados se agrupan y almacenan en archivos JSONL, organizados por fecha:

$$\text{Ruta} = \text{hdfs}://\text{data/traffic/dt=YYYYMMDD}$$

Cada archivo contiene múltiples registros independientes que representan observaciones sintéticas de tráfico.

9. Paso 5: visualización en Streamlit

Los archivos en HDFS se leen, se combinan y se transforman en un conjunto tabular. Se calculan métricas derivadas:

$$\text{vehículos/km} = \frac{T}{L}$$

y agregados por hora, región o tipo de vía. Los resultados se muestran en gráficos de líneas, mapas y tablas interactivas.

10. Conclusión

El sistema **Urban Traffic** implementa un flujo de generación sintética de datos basado en parámetros estadísticos obtenidos de un dataset real. El modelo combina estimaciones log-normales, proporciones normalizadas y muestreos gaussianos espaciales. Los datos generados se almacenan en Hadoop y se visualizan en Streamlit, permitiendo analizar volúmenes de tráfico simulados de manera realista y escalable.